深圳技术大学
SHENZHEN TECHNOLOGY UNIVERSITY

本科毕业论文（设计）

题目：基于 ViT 改进的医学影像分割

姓　　名　陈京晨

学　　院　未来技术学院

专　　业　物联网工程

学　　号　202100401013

指导教师　杨涛

职　　称　副教授

提交日期　2025 年 4 月 22 日

深圳技术大学本科毕业论文（设计）诚信声明

本人郑重声明：所呈交的毕业论文（设计），题目《基于 ViT 改进的医学影像分割》 是本人在指导教师的指导下，独立进行研究工作所取得的成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式注明。除此之外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。本人完全意识到本声明的法律结果。

毕业论文（设计）作者签名：

日期：2025 年 4 月 20 日

目 录

深圳技术大学本科毕业论文（设计）诚信声明 I

目 录 II

摘要 V

Abstract VI

1. 引言 1

1.1 研究背景与意义 1

1.2 国内外研究现状 2

1.3 本文研究内容及主要工作 5

1.4 文章结构 6

2. 相关工作 7

2.1 基于 CNN 的分割网络 7

2.2 Vision Transformers 7

2.3 用于医学图像分割的 Transformer 8

2.4 本章小结 10

3. 模型与方法 11

3.1 HiFormer 11

3.1.1 CNN 模块 12

3.1.2 Swin Transformer 模块 12

3.1.3 双层融合模块（DLF） 12

3.1.4 解码器 13

3.2 并行化补丁感知注意力模块（PPA） 13

3.3 三重注意力（Triplet Attention） 15

3.4 模块设计总结 16

3.5 本章小结 17

4. 实验与评估 18

4.1 数据集 18

4.2 实验设计 18

4.2.1 训练设置 18

4.2.2 测试设置 18

4.3 性能评估指标 19

4.3.1 Dice 系数 (Dice Similarity Coefficient, DSC) 19

4.3.2 Hausdorff 距离 (Hausdorff Distance, HD) 19

4.4 本章小结 21

5. 实验结果与分析 22

5.1 性能比较 22

5.2 可视化结果 23

5.3 讨论 24

5.4 本章小结 25

6. 结论 26

参考文献 28

致谢 32

基于 ViT 改进的医学影像分割

【摘要】随着医学影像分析技术的不断发展，精确的多脏器分割成为了临床诊断和治疗规划中的重要任务。传统的深度学习方法虽然在医学图像分割中取得了显著进展，但面对复杂的器官形态和多样的图像特征时，依然存在一定的局限性。为了进一步提升分割精度和模型的泛化能力，本文使用了一种结合注意力机制和 Transformer 模块的新型模型——HiFormer，该模型通过引入全局信息建模和局部特征学习的能力，显著提高了多脏器分割的效果。在方法部分，我们提出了在 HiFormer 模型中集成 PPA（Position-aware Attention）模块和 TA（Triplet Attention）模块，进一步增强模型在不同器官区域和结构上的分割能力。通过这种方式，HiFormer 能够更准确地捕捉到复杂的器官形状和不同解剖结构的细节，提升了分割精度。实验结果表明，所提出的 HiFormer 模型在 Synapse 多脏器分割数据集上表现优异，相较于传统的基于 CNN 的模型和现有的 Transformer 模型，HiFormer 在 Dice 系数和 Hausdorff 距离等评估指标上均取得了显著提升。此外，HiFormer 的参数量相对较小，具有较高的计算效率和较低的计算复杂度，适用于实际临床场景的应用。本文的研究表明，通过结合 Transformer 和注意力机制，能够有效提升医学图像分割任务中的性能为未来的医学影像分析和自动化诊断系统的发展提供了有价值的参考和思路。

【关键词】医学图像分割；Transformer；注意力机制；多脏器分割

Medical image Segmentation based on improved Vision Transformer

【**Abstract**】With the continuous development of medical image analysis technology, accurate multi-organ segmentation has become an important task in clinical diagnosis and treatment planning. Although traditional deep learning methods have made significant progress in medical image segmentation, they still face certain limitations when dealing with complex organ shapes and diverse image features. To further improve segmentation accuracy and model generalization ability, this paper uses a novel model, HiFormer, which combines attention mechanisms and Transformer modules. This model significantly enhances multi-organ segmentation performance by introducing the ability to model global information and learn local features. In the methodology section, we integrate the Position-aware Attention (PPA) module and Triplet Attention (TA) module into the HiFormer model, further improving the segmentation ability in different organ regions and structures. By incorporating these features, HiFormer can more accurately capture the complex shapes of organs and the details of various anatomical structures, improving segmentation precision. Experimental results demonstrate that the proposed HiFormer model performs excellently on the Synapse multi-organ segmentation dataset. Compared to traditional CNN-based models and existing Transformer models, HiFormer shows significant improvements in evaluation metrics such as Dice coefficient and Hausdorff distance. Moreover, HiFormer has relatively fewer parameters, offering high computational efficiency and low complexity, making it suitable for practical clinical applications. The research presented in this paper shows that by combining Transformers and attention mechanisms, the performance of medical image segmentation tasks can be effectively enhanced, providing valuable insights and directions for the future development of medical image analysis and automated diagnostic systems.

【**Keywords**】Medical Image Segmentation; Transformer; Attention Mechanism; Multi-Organ Segmentation

1. 引言

1.1 研究背景与意义

医学影像分割作为现代医学影像分析的核心技术之一，在现代医学诊断与治疗中具有至关重要的作用，是连接医学图像原始数据与临床应用的关键桥梁。随着计算机断层扫描（CT）、磁共振成像（MRI）、超声及正电子发射断层扫描（PET）等多模态成像技术的普及，医学影像数据呈现爆发式增长。然而，海量影像数据的背后，是临床医生对高效、精准自动化分析工具的迫切需求。通过对医学影像（如 MRI、CT、超声、X-ray 等）进行自动化分割，能够精准地识别和提取病变区域、器官轮廓及其他解剖结构，为医生提供直观、量化的病灶信息，提高诊断的准确性和效率。例如，在肿瘤检测中，精确的分割结果可以帮助医生评估肿瘤的大小、形态及发展趋势，从而制定个性化治疗方案。此外，医学影像分割在计算机辅助诊断（CAD）、手术导航、放疗规划及疾病预测等方面也发挥着重要作用。在这些医疗场景中，精准的医学影像分割能够为医生提供关键解剖结构的三维定位与量化分析，直接影响诊断的准确性、治疗方案的优化及患者预后的改善[1]。随着人工智能和深度学习技术的发展，自动化医学影像分割正逐步提高医学影像分析的智能化水平，为精准医疗和临床决策提供有力支持。

深度学习技术的突破为医学影像分割带来了革命性进展。以全卷积网络（FCN）、U-Net 为代表的卷积神经网络（CNN）通过端到端学习，实现了从像素到语义的自动映射。此类模型通过多层卷积与池化操作提取多尺度特征，结合跳跃连接（Skip Connection）融合浅层细节与深层语义信息，显著提升了分割精度与鲁棒性。例如，U-Net[2]在肝脏肿瘤分割任务中 Dice 系数可达 70%以上，远超传统方法。近年来，Transformer 模型凭借自注意力（Self-Attention）机制在自然语言处理领域大获成功[3]，其全局建模能力为医学影像分析提供了新思路。Vision Transformer（ViT）[4]通过将图像拆分为序列化补丁（Patch）并计算跨区域依赖关系，突破了 CNN 的局部性限制。

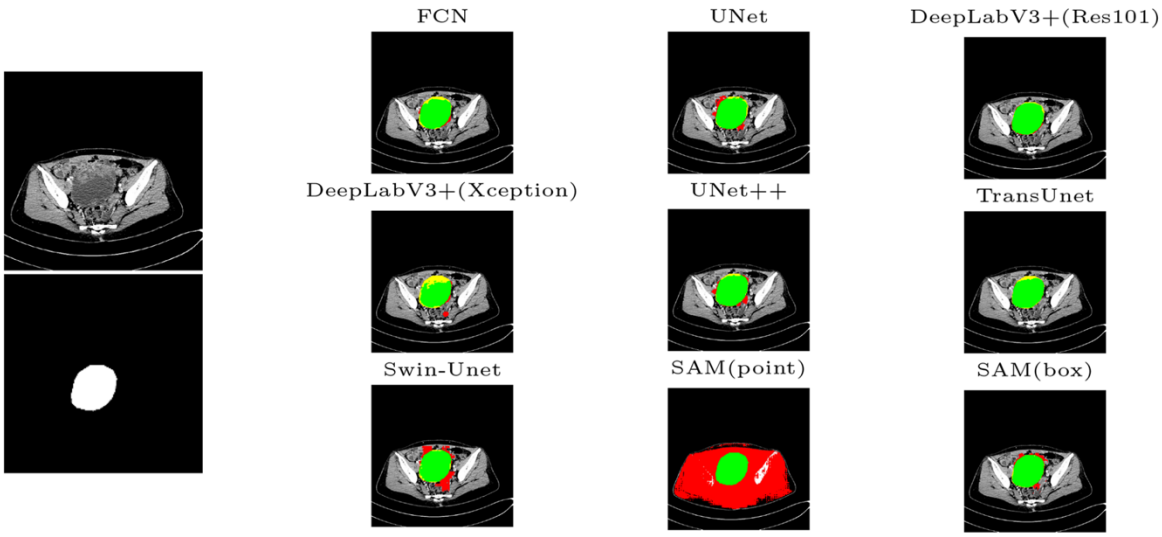

图 1.1 卵巢肿瘤数据集分割着色结果[5]

深度学习技术在医学影像分割领域的融合应用，标志着从传统人工驱动到智能自动化的重要跨越，其核心价值在于通过多维度技术突破解决临床痛点。这一技术演进极大提升肝脏肿瘤等目标识别的准确率，更通过端到端自动化处理将单例影像分析时间从小时级压缩至分钟级，极大释放了医生的生产力。同时，混合架构设计使模型能够兼容 CT、MRI 等多模态数据，并适应不同医疗设备的成像差异，为构建跨机构协作的智慧医疗平台提供了技术基础。轻量化模型的边缘部署进一步打破了资源壁垒，使得基层医疗机构也能获得三甲医院级别的分割精度，真正推动精准医疗的普惠化落地[6]。这些突破不仅重构了医学影像分析的技术范式，更为人工智能辅助诊断系统从实验室走向临床实践铺设了关键路径。

1.2 国内外研究现状

医学影像分割技术在国际上经历了从传统图像处理方法到深度学习方法的快速发展。早期的医学影像分割主要依赖于区域生长、阈值分割、活动轮廓模型等传统方法，这些方法依赖于人工特征提取，高度依赖图像质量与先验知识，对噪声、伪影及解剖结构变异敏感，难以适应不同设备、成像参数及患者个体差异带来的数据分布变化；应对多脏器交叠、病变区域边界模糊（如脑胶质瘤浸润区域）或小尺度解剖结构（如血管分支）等复杂结构时，传统方法易出现过分割或欠分割问题；并且，其人工干预成本高，算法参数需针对不同任务反复调整，分割结果需医生二次校正，严重制约临床效率。

随着计算机视觉和人工智能技术的飞速发展，深度学习已成为医学影像分割的主流方法。[7]特别是基于卷积神经网络（CNN）的分割算法[8]，如 U-Net[9]、DeepLabV3+[10]和 Attention U-Net[11]，在医学影像分析领域取得了卓越的成果，在多个医学图像数据集上表现优异。U-Net 通过编码器-解码器结构结合跳跃连接，有效提升了分割精度，并成为医学影像分割任务中的主流模型。然而，传统 CNN 主要依赖局部感受野进行特征提取，难以充分捕捉全局信息，尤其在分割形态复杂的多脏器医学图像时存在一定的局限性。

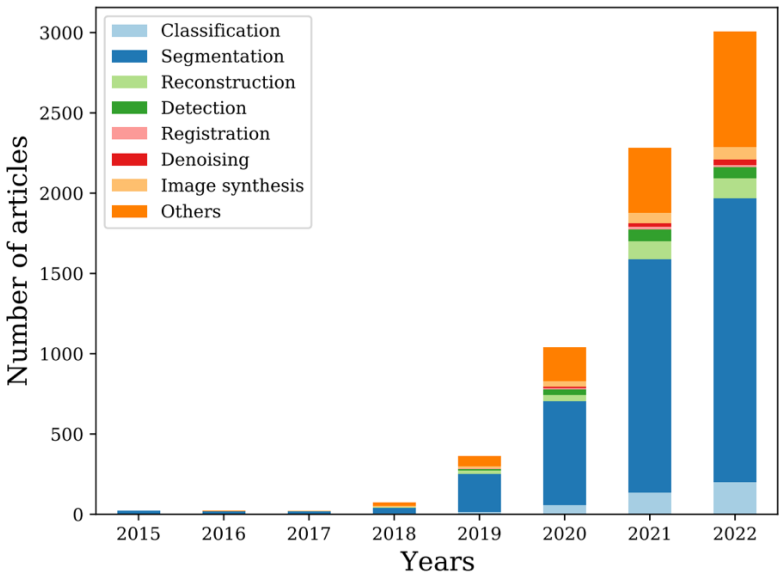

图 1.2 2015-2022 年使用 U-Net 模型作为基线解决各种医学图像分析挑战的研究成果数量[2]

近年来，随着 Transformer 在自然语言处理领域的成功，Vision Transformer（ViT）被引入到计算机视觉任务中，包括医学影像分割[12]。ViT 及其变种 Swin Transformer 通过自注意力机制有效建模长距离依赖关系，能够更好地提取全局特征[3, 13]。 然而，ViT 在医学影像中的直接应用中存在计算复杂度高、低级特征建模不足等问题。自注意力机制的时间复杂度与图像分辨率呈平方增长，对高分辨率医学影像（如全切片病理图像）计算成本难以承受。同时，ViT 缺乏 CNN 固有的平移不变性与局部特征归纳偏置，导致对边缘、纹理等低级语义的提取能力较弱。

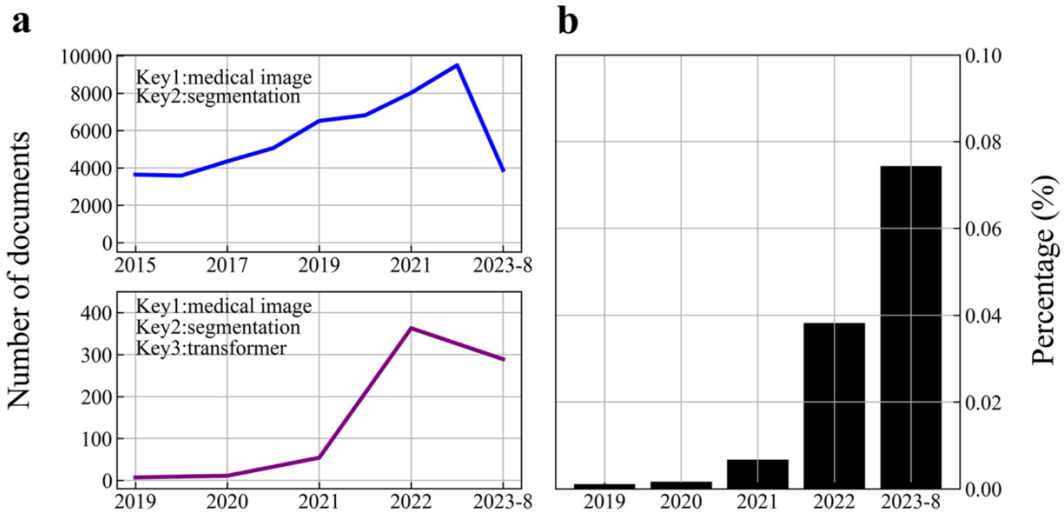

图 1.3 使用 Web of Science 检索并统计分析文献。

a 为两组关键词的文献数量统计。b 为医学图像分割中 Transformer 相关文献的比例[14]

在这一背景下，如何结合 CNN 和 Transformer 的优势，以提高分割精度和泛化能力，成为当前研究的热点问题。TransUNet[15]作为一种结合 CNN 和 Transformer 的方法，在编码器部分采用 Transformer 进行全局特征建模，在解码器部分结合 U-Net 进行局部特征恢复，取得了比传统 CNN 模型更好的性能。此外， HiFormer [16]结合 Swin Transformer 和 CNN，通过双层融合（DLF）模块有效整合局部和全局特征，提高了分割精度。

然而，在医学影像分割任务中，许多关键目标（如胰腺、血管、病变区域等）通常尺寸较小且形态复杂。在传统的 CNN 结构中，由于下采样和池化操作的存在，小目标的特征往往会在深层网络中被逐渐丢失，导致模型在小目标检测上的性能下降。此外，医学影像通常包含不同尺度的解剖结构，如何在分割过程中有效融合多尺度信息，提高模型在不同尺度下的适应性，是医学影像分割的一个关键挑战。同时，传统的注意力机制（如 CBAM[17]）主要关注通道维度或空间维度的信息，而忽略了跨维度的相互关系。这种方法在捕捉医学影像的复杂结构时存在局限性，尤其是在多器官分割任务中，不同解剖结构之间的相互关联较强，仅考虑单一维度的注意力可能导致信息缺失。此外，现有的方法通常涉及维度降维，从而影响特征表达的完整性。

1.3 本文研究内容及主要工作

针对当前医学影像分割方法普遍面临的挑战，如全局信息建模不足、局部细节丢失以及模型计算复杂度高等问题，本文对现有基于 CNN 与 Transformer 的混合架构进行了系统性分析。基于这些分析，提出了一种基于 HiFormer 的多层级医学影像分割网络。本文的主要工作如下：

第一，针对现有混合架构中多尺度特征交互低效的问题，引入了并行化补丁感知注意力（Parallelized Patch-aware Attention, PPA）[18]模块。通过多尺度注意力机制，增强模型对细节信息的捕捉能力，提高对复杂器官结构的分割效果，提高分割精度。采用并行局部卷积、全局 Transformer 与多分支特征重组策略，构建跨分辨率特征金字塔，增强局部和全局特征的表达能力，显著提升了模型对器官边界模糊区域和小尺度结构的敏感性，提高模型在不同尺度下的适应性。

第二，针对传统注意力机制通道和空间信息的跨维度交互问题，引入了轻量化三重注意力（Triplet Attention, TA）[19]模块。该模块通过三重分支结构，分别建模通道-高度（C-H）、通道-宽度（C-W）以及空间（H-W）之间的依赖关系，确保跨维度信息的充分交互。同时，三重注意力模块采用高效的计算方式（如 Z-pool 和 轻量级卷积层），在提升特征表达能力的同时，减少计算开销，使得其能够集成到不同的主干网络中，提高分割模型的整体性能。通过跨通道、空间和特征维度的交互，提高模型对关键细节特征的的感知能力。

第三，本研究在 Synapse 多脏器分割数据集[20]上对 HiFormer 进行了全面实验评估，采用 Dice 系数（DSC） 和 95% Hausdorff 距离（HD95） 等指标进行定量分析，并与 U-Net、TransUNet、Swin-Unet [21]等主流医学影像分割方法进行了对比实验，以验证 HiFormer 的优越性。此外，我们还通过消融实验研究了 PPA 和 Triplet Attention 模块对模型性能的贡献，进一步证明了其在医学影像分割任务中的有效性。在临床应用方面，我们分析了 HiFormer 在不同器官分割任务中的表现，并评估了其可解释性和鲁棒性。研究结果表明，HiFormer 具有较强的适应性和泛化能力，为医学影像分割任务提供了一种高效且精准的解决方案。这一研究不仅提升了医学影像自动化分析的水平，也为未来的计算机辅助诊断和临床决策支持 提供了重要的技术借鉴。

1.4 文章结构

本文的结构安排如下：

第 1 章，本章介绍医学影像分割的背景及研究意义，综述国内外研究现状，明确本文的研究内容、主要工作及创新点。

第 2 章，本章回顾医学影像分割领域的相关研究，重点介绍基于 CNN 和 Transformer 的分割方法，并讨论其优缺点。同时，总结当前研究面临的挑战，为本文提出的 HiFormer 模型奠定理论基础。

第 3 章，本章详细介绍本文提出的 HiFormer 模型，包括 CNN 编码器、Swin Transformer 模块、双层融合（DLF）模块、并行化补丁感知注意力（PPA）模块以及三重注意力（TA）模块。通过结构分析和示意图展示 HiFormer 的工作机制，并解释各模块的设计原理和作用。

第 4 章，本章介绍实验的设计和实施方案，包括数据集的选择、训练和测试设置、评价指标等。同时，详细描述实验的具体步骤，确保实验的可重复性。

第 5 章，本章展示 HiFormer 在 Synapse 多脏器分割数据集上的实验结果，并与主流分割方法进行性能对比。通过定量评估（如 Dice 系数和 Hausdorff 距离）和定性分析（可视化分割结果）验证 HiFormer 的优越性。此外，本章还通过消融实验分析各模块对模型性能的贡献。

第 6 章，本章总结本文的研究成果，并探讨 HiFormer 在医学影像分割领域的应用前景。同时，指出当前研究的局限性，并对未来可能的研究方向进行展望。

2. 相关工作

2.1 基于 CNN 的分割网络

卷积神经网络（CNN）一直是医学图像分割领域的主流方法。由于其在图像局部特征提取方面的优势，CNN 在医学图像分割任务中取得了显著成果。最经典的网络之一是 U-Net，它通过编码器-解码器结构实现了高效的上下文信息捕捉，并结合跳跃连接有效地融合了不同尺度的特征。这种结构特别适用于处理医学图像中的细粒度特征，能够在保持分割精度的同时减少计算开销。

卷积神经网络（CNN）已成为医学和工业图像分割任务中的主流方法，凭借其强大的特征提取能力，在多种应用场景中展现出卓越性能。例如，在激光线能量沉积（LW-DED）增材制造过程中，CNN 被用于熔池检测与分割，实现实时过程监测和稳定性评估。其中，YOLOv8l 在不锈钢和低碳钢基材上的平均精度分别达到 0.925 和 0.853，展现出 CNN 在高精度实时分割任务中的应用潜力[22]。此外，在路面裂缝检测任务中，CNN 结合多尺度上下文融合和注意力机制，进一步提升了分割精度。通过引入广义 Dice 损失函数解决类别不平衡问题，CNN 在多项评估指标上超越其他先进模型，F1-score 达 0.7968，均交并比（mIoU）达 0.8094[23]，展现了 CNN 在工业检测领域的巨大潜力。

CNN 通过卷积层提取特征、池化层降维、跳跃连接增强细节信息，成为图像分割的核心方法。随着网络结构的不断发展，越来越多的基于 CNN 的改进方法被提出。例如，DeepLab 系列模型[10]通过引入空洞卷积（dilated convolution）来扩大感受野，从而增强对多尺度信息的建模能力；而 Attention U-Net[24]则结合了注意力机制，使得模型能够自适应地关注图像中的重要区域，提升了分割的准确度。然而，尽管 CNN-based 方法在医学图像分割中取得了较好效果，它们仍然受到局部特征提取能力的限制，且很难充分利用图像中的全局信息。

2.2 Vision Transformers

近年来，Vision Transformer（ViT）作为一种全新的图像处理模型，凭借其强大的全局信息建模能力，在计算机视觉任务中取得了突破性进展。与传统的卷积操作不同，ViT

通过将图像分割为一系列的非重叠 patch，并对这些 patch 进行序列化后输入到 Transformer 模型中，从而使得模型能够学习到长程依赖关系和全局特征。ViT 的自注意力机制使其在图像处理上具备了比 CNN 更强的表达能力，特别是在大规模数据集上，ViT 展现出了优于传统 CNN 的表现。

在水灾检测领域，ViT 被用于 SAR 图像变化检测，以克服 SAR 图像的 speckle 噪声和相似散射信号问题。研究提出 DAM-Net（Differential Attention Metric-based Network），结合时序特征交互和类标记（Class Token）方法，使模型专注于水体变化而非整个场景，实现 97.8% 的总体精度、96.5% F1 分数、93.2% IoU，显著优于传统方法[25]。在目标检测与分类任务中，研究者提出 IntelPVT（Intelligent Patch-based Pyramid Vision Transformer），通过智能 patch 机制提升 ViT 在不同尺度上的适应性，有效减少固定 patch 大小带来的信息损失。实验表明，在 MSCOCO、Pascal VOC 和 Cityscapes 数据集上，该方法在高置信度阈值下表现优异，提高了目标检测和分类任务的准确性[26]。此外，ViT 还被用于口腔癌图像分类，在移动设备拍摄的癌症图像任务中，ViT 和 Swin Transformer 相较于传统 CNN（如 VGG19、ResNet50）展现更优性能。Swin Transformer 在二分类任务中达到了 88.7% 的准确率，比 ViT 高 2.3%，比 VGG19 高 3.5%[27]，进一步验证了 Transformer 模型在医学影像分析中的潜力。

ViT 模型的成功催生了多个变体，例如 DeiT（Data-efficient Transformer）[28]和 Swin Transformer，这些变体在不同的计算机视觉任务中取得了优秀的成绩。特别是 Swin Transformer 通过引入分层设计和局部窗口的自注意力机制，不仅提升了计算效率，还增强了在复杂场景下的特征建模能力。尽管 ViT 通过自注意力机制有效建模长距离依赖关系，在遥感检测、目标识别、医学影像分类等领域展现了超越 CNN 的优势，但仍面临着如何有效处理高分辨率图像、如何结合局部特征与全局特征的挑战。

2.3 用于医学图像分割的 Transformer

随着 Transformer 模型在计算机视觉领域的成功，研究者们也开始将其引入到医学图像分割任务中。Transforme 在医学图像分割中的应用主要依赖于其强大的自注意力机制，能够捕捉图像中的全局信息并增强跨区域的特征交互。这一优势使得 Transformer 在医学图像分析中的潜力巨大，尤其是在处理包含复杂背景和多尺度特征的医学图像时。

一些 Transformer-based 医学图像分割模型，如 TransUNet 和 Swin-UNet，已在多个医学数据集上取得了良好的效果。TransUNet 将 U-Net 的编码器-解码器架构与 Transformer 结合，通过在编码器中使用 Transformer 层来增强对全局信息的建模，同时保持 U-Net 在解码器部分的优势[15]。Swin-UNet 则将 Swin Transformer 引入到医学图像分割中，通过分层自注意力机制更好地处理大规模图像数据[21]。DAE-Former（Dual Attention-Guided Efficient Transformer） 通过改进自注意力机制 以增强空间和通道特征表达，并重新设计跳跃连接（Skip Connection），引入交叉注意力模块（Cross-Attention Module），提高特征复用能力和定位精度。在多器官心脏和皮肤病变分割任务中，该方法在无预训练权重的情况下，依然超越了主流方法[29]。MAXFormer 采用 U 形分层网络结构，将 Transformer 的自注意力机制拆分为局部-全局注意力（Local-Global Attention）和外部注意力（External Attention）。局部注意力分支用于捕捉高频细节信息，而全局注意力分支则专注于低频全局信息。此外，精细融合连接（Refined Fused Connection） 进一步优化了编码器和解码器的特征交互，使得 MAXFormer 在医学图像分割数据集上取得了领先性能，且无需大规模预训练[30]。CSWin-UNet 结合交叉窗口自注意力（Cross-Shaped Windows Self-Attention, CSWin），在 U-Net 结构中引入 水平和垂直条状自注意力，提高计算效率和感受野交互能力。此外，该方法采用 基于内容的特征重组操作（Content-Aware Reassembly Operator），通过预测的卷积核自适应调整特征分辨率，使得模型在 Synapse 多脏器 CT、心脏 MRI 和皮肤病变数据集上表现优异[31]。总体而言，Transformer 在医学图像分割领域的应用主要集中于优化自注意力机制、提升计算效率、增强局部与全局信息融合。诸如 DAE-Former、MAXFormer、CSWin-UNet 等新型架构通过高效注意力机制和创新的特征融合策略，在医学影像分析任务中展现出卓越的性能，推动了计算机辅助诊断（CAD）的发展。

尽管 Transformer 在医学图像分割中展现出了优异的性能，但其仍然面临一些挑战。例如，由于自注意力机制计算量较大，Transformer 模型的训练和推理速度往往较慢，特别是在处理高分辨率医学图像时。此外，如何将局部信息与全局信息有效结合，以提高分割精度和鲁棒性，仍是医学图像分割领域亟待解决的问题。

2.4 本章小结

本章综述了当前医学图像分割领域的主流方法，重点介绍了基于 CNN 和 Transformer 的网络架构及其在医学与工业图像处理中的应用与发展。CNN 由于其强大的局部特征提取能力，在早期医学图像分割任务中占据主导地位，代表性方法如 U-Net、DeepLab 系列和 Attention U-Net 等通过编码器-解码器结构、空洞卷积和注意力机制在多个实际任务中取得了优异表现。然而，CNN 在捕捉全局上下文信息方面存在天然局限。近年来，随着 Transformer 在计算机视觉领域的兴起，其强大的全局建模能力逐渐弥补了 CNN 的不足。ViT 及其改进版本（如 Swin Transformer、DeiT）在多个任务中展现出超越传统 CNN 的性能。基于此，研究者开始将 Transformer 引入医学图像分割，涌现出如 TransUNet、Swin-UNet、DAE-Former、MAXFormer 和 CSWin-UNet 等一系列融合结构，这些模型通过优化注意力机制、重设计跳跃连接、引入局部-全局注意力分支等方式，显著提升了分割精度和模型泛化能力。尽管 Transformer 在医学图像分割中展现出巨大潜力，但其高计算成本与较慢的训练、推理速度仍是亟需解决的问题。此外，如何在保持全局信息建模能力的同时，更有效地整合局部细节信息，是未来研究的重要方向。因此，将 CNN 与 Transformer 优势互补，构建高效、精准的混合型分割模型，或将成为医学图像分割技术演进的关键路径。

3. 模型与方法

3.1 HiFormer

Heidari 等人提出的 HiFormer 模型[16]是一种结合卷积神经网络（CNN）和 Transformer 的医学图像分割方法。医学图像分割任务要求模型能够高效捕捉图像中的全局语义信息和局部空间信息。传统的 CNN 在建模局部空间信息方面有优势，但在长距离依赖性建模上存在局限。Transformer，尤其是 Vision Transformer（ViT），能够捕捉全局特征，但对低级特征的提取较弱。因此，HiFormer 通过融合 CNN 和 Transformer 的优势来克服这两种结构的局限。

HiFormer 模型设计了两种多尺度特征表示：基于 CNN 的编码器和基于 Swin Transformer 的模块。CNN 模块负责提取局部特征，而 Swin Transformer 模块负责捕捉全局信息。为了高效融合这两类特征，HiFormer 引入了双层融合（DLF）模块。实验表明，该模型在多个医学图像分割数据集上优于其他基于 CNN、Transformer 及混合方法的模型。

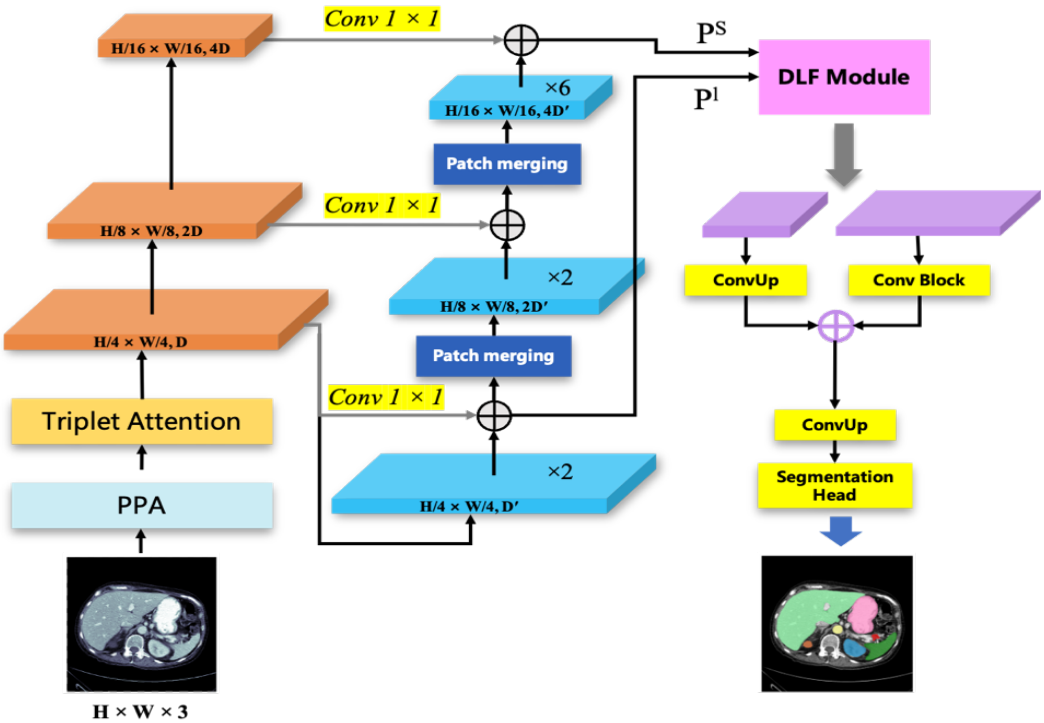

图 3.1 所提 HiFormer 的概述

3.1.1 CNN 模块

HiFormer 的编码器首先利用 CNN 作为特征提取器，通过多个卷积层和池化操作提取不同分辨率的中间特征图。输入图像 $X \in R^{H \times W \times C}$ 首先进入 CNN 模块，该模块由多个卷积层组成。通过卷积操作，将图像转化为多个金字塔式的中间特征图。在该过程中，采用了$Conv\ 1 \times 1$卷积层进行跳跃连接，将特征图送入后续的 Transformer 模块，从而弥补 Transformer 在低层次特征建模上的不足。

3.1.2 Swin Transformer 模块

Swin Transformer 是为了解决传统 Transformer 在高分辨率任务中效率低下的问题而提出的。Swin Transformer 通过引入窗口化自注意力（W-MSA）和移动窗口自注意力（SW-MSA）机制，能够有效地减少计算复杂度并提高效率[4, 21]。

在 HiFormer 中，Swin Transformer 模块接收来自 CNN 模块的低分辨率特征，并通过1×1卷积生成大小为 $(\mathrm{H}/4\ \times \mathrm{W}/4)$ 的特征补丁（tokens）。这些补丁经过第一个 Swin Transformer 模块后生成第一个基于注意力的特征图。通过跳跃连接，将先前的激活值与新生成的特征图进行融合。接着，应用补丁合并策略，将相邻的补丁合并以减少分辨率，并通过线性层调整嵌入维度。这一过程能够在低分辨率图像上捕获到全局的语义信息。

3.1.3 双层融合模块（DLF）

双层融合（DLF）模块是 HiFormer 中的一个关键创新，旨在有效融合来自 CNN 和 Swin Transformer 的多尺度特征。由于浅层特征（如 P^s ）具有较强的定位信息，而深层特征（如 P^l ）包含更多的语义信息，HiFormer 在特征融合过程中保留了最浅层和最深层的特征，确保了模型能够同时处理定位和语义信息[16]。

在 DLF 模块中，交叉注意力机制被用来融合来自不同层级的特征。具体来说，最小层级 P^s和最大层级 P^l 的输出通过交叉注意力机制进行信息融合，从而保留局部和全局特征的有效信息。这种融合策略确保了特征在空间和语义上的一致性，提高了模型的分割精度。

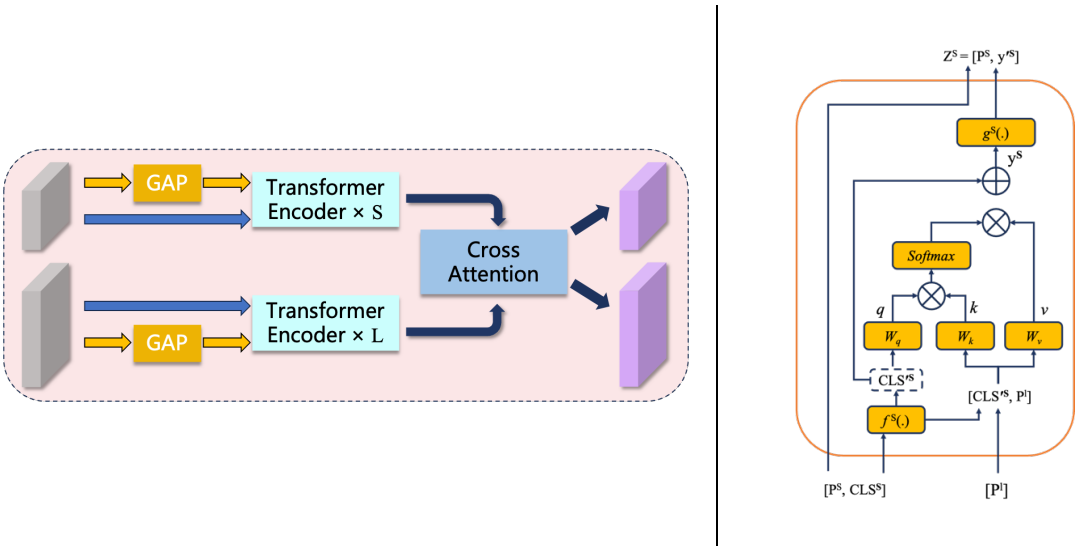

图 3.2 DLF 模块和交叉注意力[16]

3.1.4 解码器

HiFormer 的解码器部分受到 Semantic FPN[32]的启发，设计了一个能够融合不同层级特征的结构。解码器接收来自 DLF 模块的低分辨率和高分辨率特征图 P^s 和 P^l，并通过卷积上采样（ConvUp）操作将它们恢复到更高分辨率。解码器通过一系列卷积操作和激活函数将这两种特征图结合，最终生成一个统一的特征图。这个特征图随后传递到分割头进行最终的医学图像分割。

具体来说，解码器首先对 P^s和 P^l 进行卷积上采样操作，通过一系列的卷积层、组归一化和 ReLU 激活函数，恢复到中等分辨率的特征图。最后，这两个特征图会被加和并进一步通过卷积操作生成最终的分割掩膜。

3.2 并行化补丁感知注意力模块（PPA）

为了进一步提高模型的性能，特别是在小物体检测和复杂图像内容分割方面，在 HiFormer 的基础上引入了并行化补丁感知注意力（Parallelized Patch-aware Attention, PPA）模块[18]。PPA 模块的主要设计目标是解决网络编码器和解码器中多次下采样操作导致的小目标信息丢失的问题。PPA 采用多分支特征提取策略，每个分支在不同的尺度和层次上捕捉图像的特征。PPA 通过局部、全局和卷积分支捕获图像的多尺度信息，能够有效提高模型在小物体和细节信息分割中的准确性。

PPA 模块采用多分支策略，包括本地分支（补丁大小为 2）、全局分支（补丁大小为 4）和串行卷积分支。这些分支并行工作，捕获不同尺度的特征。接着，通过通道注意力和空间注意力机制进一步优化特征，确保小目标的细节被保留和增强。除了传统的卷积操作，PPA 模块使用余弦相似度进行特征选择，这在图像处理中较为少见，通常更多用于自然语言处理。这种方法帮助重新加权和选择相关的标记和通道，优化了任务特定参数，增强了小目标的检测能力。

PPA（Patch-based Pyramid Attention）模块采用多尺度特征提取与注意力协同优化机制，其核心结构由多分支特征提取和注意力增强模块组成。首先，输入特征张量 $F \in \mathbb{R}^{H' \times W' \times C'}$通过逐点卷积调整维度后，并行输入三个特征分支：(1) 本地分支采用补丁分割策略（p=2）进行局部自注意力计算，捕获细粒度空间交互；(2) 全局分支扩展感受野（p=4），通过大尺寸补丁划分建模长程依赖关系；(3) 串行卷积分支通过三组级联 3×3 卷积（替代传统大核卷积）构建深度可分离结构，生成具有归纳偏置的特征响应 F_{conv}。三路分支特征经自适应加权融合后，采用基于余弦相似度的动态特征选择机制，通过可学习参数优化通道与空间维度的特征相关性。随后，融合特征 F~通过双重注意力增强：通道注意力模块生成通道权重矩阵 $M_c \in \mathbb{R}^{1 \times 1 \times C'}$实现通道维度的特征重标定，空间注意力模块生成空间掩码 $M_s \in \mathbb{R}^{H' \times W' \times 1}$聚焦关键区域。最终经过 Dropout 正则化、批归一化与 ReLU 激活的非线性变换，输出优化后的特征 $F'' \in \mathbb{R}^{H \times W \times C'}$。该架构通过局部-全局特征互补、卷积-注意力的协同优化，实现了多尺度语义信息的有效建模。

PPA 模块的设计通过三个并行分支分别计算局部、全局和卷积层的特征，并将其融合生成更全面的特征表示。最终，通过通道注意力和空间注意力机制，模型能够自适应地选择重要特征进行处理。这一模块在保持计算效率的同时，极大地提升了模型在复杂医学图像分割任务中的表现。

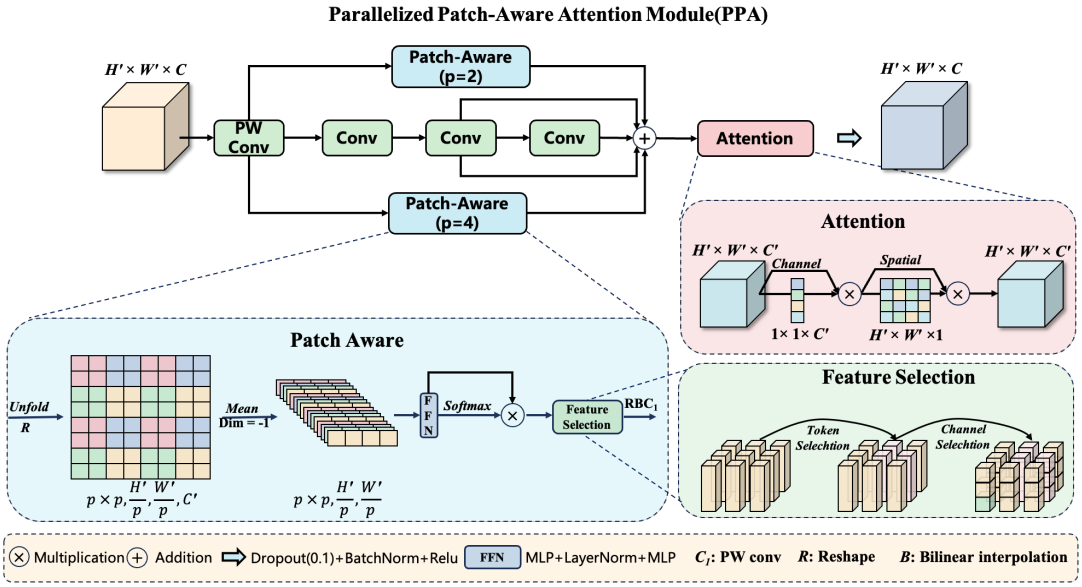

图 3.3 并行化补丁感知注意力模块的详细结构。该模块主要由两个部分组成：多分支融合和注意力机制。多分支融合部分包括补丁感知卷积和拼接卷积。补丁感知中的“p”参数设置为 2 和 4，分别代表局部和全局分支[18]

3.3 三重注意力（Triplet Attention）

在提高模型性能的过程中，在 HiFormer 的基础上还引入了三重注意力（Triplet Attention，TA）模块[19]。TA 模块的设计其目的是通过捕捉通道和空间维度之间的交互来增强卷积神经网络的性能。这一模块通过高效地捕获跨维度交互，进一步提高了模型对图像中细粒度信息的感知能力。三重注意力模块通过三个分支分别捕获空间维度和通道维度之间的跨维度交互，从而增强了模型对细节特征的敏感性。

TA 模块由三个分支组成，每个分支处理不同类型的交互：通道与宽度、通道与高度，以及高度与宽度的空间依赖关系。通过旋转操作和 Z-pool 层（结合最大和平均池化）减少维度，之后使用卷积层生成注意力权重，最终通过平均聚合分支输出。它避免了维度缩减，从而保留更多信息并减少计算成本，能够提升在有限资源下的模型表现。

三重注意力模块通过三维正交分解策略实现跨维度特征交互，其核心包含三个特征重构分支：(1) 通道-宽度协同分支将输入张量 X∈ℝ^{C×H×W}沿 H 轴逆时针旋转 90°得到 W×H×C 特征立方体，通过 Z-pool 层（沿 W 维执行最大-平均池化压缩）生成 2×H×C 特征图；(2) 通道-高度交互分支将输入沿 W 轴旋转 90°获得 H×C×W 特征表示，经 Z-

pool 压缩为 2×C×W；(3) 空间依赖分支保留原始 H×W 空间结构，Z-pool 输出 2×H×W 降维特征。各分支随后采用 k×k 卷积核（通常 k=7）进行跨维度特征融合，经批归一化与 Sigmoid 激活生成三维注意力权重矩阵。通过逆向旋转操作将前两个分支的输出恢复至 C×H×W 原始维度后，采用元素级乘法实现注意力重标定，最终通过三路特征平均聚合得到输出 $y=\frac{1}{3}(\overline{y_1}+\overline{y_2}+y_3)$，其中$\overline{y_1}$和$\overline{y_2}$是第一和第二分支的旋转回原状后的输出，$y_3$是第三分支的输出。该机制通过张量旋转解耦空间-通道维度关联，结合 Z-pool 的双重池化策略增强特征鲁棒性，实现了通道-空间交叉注意力与空间自注意力的协同优化。

三重注意力的设计考虑到了空间和通道维度之间的相互依赖性，并通过 Z-pool 层在计算开销和性能之间取得了平衡。该模块通过高效的计算方式捕捉跨维度特征，进一步提升了模型在医学图像分割中的性能。

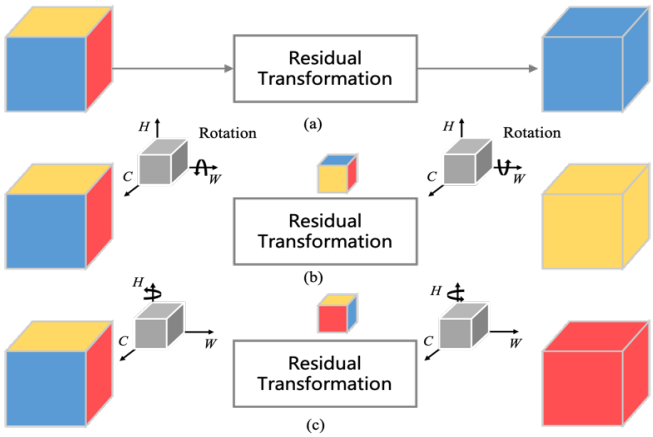

图 3.4 三分支三元组注意力的抽象表示，捕捉跨维度交互。给定输入张量，三元组注意力通过旋转输入张量并进行残差变换，从而捕捉维度之间的依赖关系[19]

3.4 模块设计总结

本文提出的 HiFormer 模型通过结合 CNN 和 Transformer 的优势，并通过双层融合（DLF）、并行化补丁感知注意力（PPA）和三重注意力（Triplet Attention）模块的创新设计，成功地提高了医学图像分割任务中的性能。模型在局部和全局特征的融合、复杂小物体的检测、跨维度特征的捕捉等方面表现出了显著优势。通过这些模块的结合，HiFormer 能够高效地处理医学图像中的复杂结构，提供精确的分割结果。

3.5 本章小结

本章围绕医学图像分割中性能优秀的 HiFormer 模型展开，详细介绍了其关键结构与模块设计。首先，HiFormer 通过融合卷积神经网络（CNN）和 Swin Transformer，实现了局部空间信息与全局语义信息的有效协同。为克服不同特征层之间的信息鸿沟，模型引入了双层融合（DLF）模块，通过交叉注意力机制强化浅层定位特征与深层语义特征的融合，有效提升了分割精度。为了进一步增强模型对小目标与复杂结构的感知能力，在 HiFormer 基础上集成了并行化补丁感知注意力（PPA）模块。PPA 通过局部、全局和卷积分支构建多尺度感知机制，并辅以通道和空间注意力，有效保留图像中的细粒度信息。此外，加入的三重注意力（Triplet Attention, TA）模块进一步拓展了模型在通道与空间维度上的表达能力。TA 模块通过三个分支分别建模跨维度的依赖关系，以低计算开销提升模型感知能力，对精细结构的分割具有重要意义。总体而言，HiFormer 通过 CNN 与 Transformer 结构的互补融合，并结合 DLF、PPA 和 TA 三大模块，实现了对医学图像中局部细节与全局结构的高效建模。本章内容为后续的实验验证与模型性能分析奠定了坚实的理论基础。

4. 实验与评估

4.1 数据集

Synapse 多脏器分割：Synapse 多脏器分割数据集[20]是我们评估 HiFormer 性能的主要数据集。该数据集包含 30 个病例，每个病例包含多个轴位腹部 CT 图像，总共有 3779 张图像。每张 CT 图像包含 85 到 198 张 512×512 像素的切片，体素空间分辨率为 ([0.54 ~ 0.54] × [0.98 ~ 0.98] × [2.5 ~ 5.0]) mm^3。这些图像涉及多个脏器，包括肝脏、肾脏、脾脏等，具有较高的解剖学复杂性和多样性，因此是医学图像分割任务的一个标准基准数据集。

4.2 实验设计

4.2.1 训练设置

在我们的实验中，HiFormer 模型在 PyTorch 框架下实现，并使用单个 NVIDIA Tesla V100 GPU (GV100GL，32 GB 内存) 进行训练。输入图像的大小被设定为 224 × 224 像素。批量大小和学习率分别设置为 10 和 0.01。为了提高模型的泛化能力，我们采用了在 ImageNet 数据集上预训练的 CNN 和 Swin Transformer 模块的权重来初始化模型参数。

训练过程中，我们使用了随机梯度下降（SGD）优化器，动量为 0.9，权重衰减为 0.0001。在每个训练周期中，我们采取了多种数据增强方法，包括图像翻转、旋转以及随机裁剪等，以增加训练样本的多样性并防止过拟合。每个训练周期结束后，使用验证集进行模型评估，以便调整超参数并选择最佳模型。

4.2.2 测试设置

在测试阶段，我们使用独立的测试集进行评估，所有实验均在相同硬件环境下进行，以确保公平比较。在分割任务中，输出的分割图与真实标签进行比对，使用一系列标准指标对模型性能进行评估。

4.3 性能评估指标

我们使用以下指标对模型进行评估：

4.3.1 Dice 系数 (Dice Similarity Coefficient, DSC)

Dice 系数（Dice Similarity Coefficient, 简称 DSC）是一种衡量两个样本集合相似度的指标，由 Lee Raymond Dice 于 1945 年提出，最初用于生态学中物种分布的相似性分析。随着数据科学与人工智能的发展，Dice 系数被广泛应用于计算机视觉、自然语言处理、生物信息学等领域，尤其在医学图像分割中被视为衡量模型分割性能的重要评价指标。

给定两个集合 A 和 B，Dice 系数定义为：

$$D(A,B)=\frac{2\times|A\cap B|}{|A|+|B|}$$

其中：|A| 和 |B| 分别表示集合 A 和 B 的元素个数；|A∩B| 表示两个集合的交集，即共同包含的元素数目。

在图像分割中，A 通常表示预测的分割区域，B 表示真实的标注区域。此时，Dice 系数的计算可以转换为像素级的二分类问题，设：TP：预测为正类且真实为正类的像素数（True Positive）；FP：预测为正类但真实为负类的像素数（False Positive）；FN：预测为负类但真实为正类的像素数（False Negative）；则 Dice 系数可等价表示为：

$$DSC=\frac{2TP}{2TP+FP+FN}$$

Dice 系数的取值范围为 [0, 1]，其中 0 表示完全不重合，1 表示完全一致；Dice 系数满足对称性，即 DSC (A, B) = DSC (B, A) ；由于采用的是交集的两倍作为分子，它对交集部分的增加非常敏感，适用于小目标的准确性评估；与精确率（Precision）和召回率（Recall）相比，Dice 系数尤其在前景目标远小于背景的情况下对于类别不平衡的问题更为稳健。

4.3.2 Hausdorff 距离 (Hausdorff Distance, HD)

95% Hausdorff 距离（HD95）是另一项常用的评估指标，用于衡量预测边界和真实边界之间的最大偏差。它是通过计算所有点对之间的最大距离来评估模型对边界的准确性。HD 越小，表示分割结果的边界与真实边界之间的偏差越小。

Hausdorff 距离（Hausdorff Distance, 简称 HD）是一种用于衡量两个点集之间最大差异的指标，由德国数学家 Felix Hausdorff 于 1914 年提出。与 Dice 系数这类衡量整体重叠程度的相似性指标不同，Hausdorff 距离关注的是形状边界之间的最大偏移量，因此在评估图像分割的边界准确性时具有重要意义。特别是在医学图像分割中，HD 能够反映模型在轮廓或边界处的最坏情况误差。

其数学定义如下：设 $A = \{a_1, a_2, \dots, a_m\}$ 与 $B = \{b_1, b_2, \dots, b_n\}$ 是欧几里得空间中两个有限点集，则从集合 A 到 B 的定向 Hausdorff 距离定义为：

$$h(A,B) = \max_{a \in A} \min_{b \in B} |a - b|$$

即：对集合 A 中的每一个点 a，找到与其最近的 B 中的点 b，计算最小距离，再从所有这些最小距离中取最大值。

而双向 Hausdorff 距离定义为：

$$H(A,B) = \max\{h(A,B), h(B,A)\}$$

此定义保证了对称性，即 H(A,B)=H(B,A)，并真实反映了两个点集在几何空间中最远边界点之间的距离。

Hausdorff 距离对局部边界误差非常敏感，能捕捉到分割结果中最极端的不匹配点。与 Dice 系数类似，H(A,B)=H(B,A)，Hausdorff 距离具有对称性；即使两个区域之间没有重叠，只要边界接近，Hausdorff 距离仍可能较小，这与 Dice 系数形成互补；在医学图像分割中，HD 可以直观理解为预测分割轮廓与真实标注轮廓之间的最大空间偏差，单位通常以像素或毫米计。

由于原始 Hausdorff 距离极度敏感于异常值（如噪声点或少量误差点），在实际应用中常采用**百分位 Hausdorff 距离**，例如：

$$HD_{95}(A,B) = 95\%\text{-percentile of all } \{\min_{b \in B} |a - b|, \forall a \in A\} \cup \{\min_{a \in A} |b - a|, \forall b \in B\}$$

即：计算所有从 A 到 B，以及从 B 到 A 的最小距离，取其第 95 百分位作为最终度量。这样做可以有效减少单个极端值对整体度量的影响，提高评估的鲁棒性。

表 4.1 不同指标的对比

指标	衡量内容	对边界敏感	对整体重叠敏感	适用场景
Dice 系数	区域重叠程度	否	是	整体分割性能评估
Hausdorff 距离	边界最大偏移量	是	否	边界精度、最坏情况误差评估
IoU	区域交并比	否	是	语义分割评价、目标检测

为了确保结果的公平性，我们将引入了 PPA 和 Triplet Attention 模块的 HiFormer 模型与几种基准方法进行了对比，分别包括基于 CNN 的方法、基于 Transformer 的方法，以及混合模型方法。这些对比实验帮助我们更好地理解 HiFormer 的优势和局限性，并验证其在多脏器医学图像分割任务中的表现。

4.4 本章小结

本章围绕 HiFormer 模型在 Synapse 多脏器分割数据集上的实验设计与性能评估展开。首先，我们详细介绍了实验所使用的数据集，其涵盖多个具有复杂解剖结构的脏器，具有较高的挑战性和代表性。随后，阐述了训练与测试的具体设置，包括模型训练的环境配置、参数选择、数据增强策略以及评估流程，确保实验过程的可重复性与公平性。在性能评估方面，我们引入了 Dice 系数和 Hausdorff 距离两项关键指标，分别从整体区域重叠程度和边界偏移精度两个维度对模型表现进行全面分析。这些指标互为补充，能够从不同角度揭示模型在图像分割任务中的强弱项。

5. 实验结果与分析

5.1 性能比较

在本节中，我们展示了 HiFormer 模型与其他基准方法（包括 DARR[33]、U-Net[9]、R50 U-Net[15]、Att-UNet [24]等）在 Synapse 多脏器分割数据集上的性能比较。以下是各个模型的性能指标（包括 DSC 和 HD）。

PPA 模块的影响：PPA 模块通过优化多尺度信息融合，使得模型能更好地捕捉脏器的细节边界，从而提高了 DSC 指标（在原模型基础上提升了 0.89%）。这在多个模型（如 HF+PAA 和 HF+TA+PPA）中得到了验证，尤其在 HF+PAA 模型的胰腺部分识别提升最为显著，相比于原模型提升了 2.11%。

Triplet Attention 模块的影响：TA 模块进一步提升了模型的局部特征学习能力，特别是在处理复杂解剖结构（如脾和胃）时表现得尤为突出。添加 TA 模块的 HiFormer 版本（HF+TA）在一些脏器的分割中取得了比单独使用 PPA 模块更优的结果。在 HiFormer 基础上添加 Triplet Attention 模块将 DSC 指标提升了 1.14%，同时 HD 指标下降了 3.82。

而同时添加 PPA 模块和 Triplet Attention 模块的模型（HF+TA+PPA）在 DSC 指标上的表现最好，相比原 HiFormer 模型提升了 1.21%，展示了 PPA 模块和 Triplet Attention 模块的协同作用对图像分割上的显著效果。

表 5.1 所提方法在 Synapse 数据集上的比较结果，红色表示最佳结果，蓝色表示第二最佳结果。

Methods	DSC↑	HD ↓	Aorta	Gallbladder	Kidney(L)	Kidney(R)	Liver	Pancreas	Spleen	Stomach
DARR [33]	69.77	-	74.74	53.77	72.31	73.24	94.08	54.18	89.90	45.96
R50 U-Net [15]	74.68	36.87	87.74	63.66	80.60	78.19	93.74	56.90	85.87	74.16
U-Net [9]	76.85	39.70	89.07	69.72	77.77	68.60	93.43	53.98	86.67	75.58
R50 Att-UNet [15]	75.57	36.97	55.92	63.91	79.20	72.71	93.56	49.37	87.19	74.95
Att-UNet [11]	77.77	36.02	89.55	68.88	77.98	71.11	93.57	58.04	87.30	75.75
R50 ViT [15]	71.29	32.87	73.73	55.13	75.80	72.20	91.51	45.99	81.99	73.95
TransUnet [15]	77.48	31.69	87.23	63.13	81.87	77.02	94.08	55.86	85.08	75.62

Methods	DSC↑	HD ↓	Aorta	Gallbladder	Kidney(L)	Kidney(R)	Liver	Pancreas	Spleen	Stomach
Swin-Unet [21]	79.13	21.55	85.47	66.53	83.28	79.61	94.29	56.58	90.66	76.60
LeVit-Unet [34]	78.53	16.84	78.53	62.23	84.61	80.25	93.11	59.07	88.86	72.76
DeepLabv3+ (CNN) [10]	77.63	39.95	88.04	66.51	82.76	74.21	91.23	58.32	87.43	73.53
HiFormer [16]	78.52	18.56	85.90	57.99	85.47	79.37	94.28	58.33	90.69	76.17
HF+PAA	79.41	20.07	84.60	64.25	84.73	79.05	93.69	60.44	89.64	78.88
HF+TA	79.64	14.74	84.44	64.83	85.30	79.29	94.19	56.51	90.91	81.62
HF+TA+PPA	79.73	20.25	85.69	65.89	85.52	80.65	94.03	58.48	89.69	77.86

为了对比模型的复杂度，我们展示了不同模型的参数数量。以下是各个模型的参数数量对比：

表 5.2 模型参数的比较

Methods	# Params(M)	DSC ↑	HD ↓
TransUnet	105.28	77.48	31.69
Swin-Unet	27.17	79.13	21.55
LeVit-Unet	52.17	78.53	16.84
DeepLabv3+ (CNN)	59.50	77.63	39.95
HiFormer	25.51	78.52	18.56
HF+PAA	25.51	79.41	20.07
HF+TA	25.51	79.64	14.74
HF+TA+PPA	25.51	79.73	20.25

从表格中可以看到，HiFormer 以及其他改进模型的参数数量较少（25.51M），但在分割精度和 HD 指标上表现出色。相较于其他模型，HiFormer 及其改进模型在保持较低参数量的同时，能够获得更好的性能。

5.2 可视化结果

下图展示了 HiFormer 模型在 Synapse 多脏器分割数据集上的一些分割结果。通过对比不同方法的分割效果，HiFormer 展现了较高的准确性和细致的脏器边界捕捉能

力。尤其在一些较小的脏器（如胰腺和肾脏）的分割上，HiFormer+TA+PPA 显示出更好的性能。

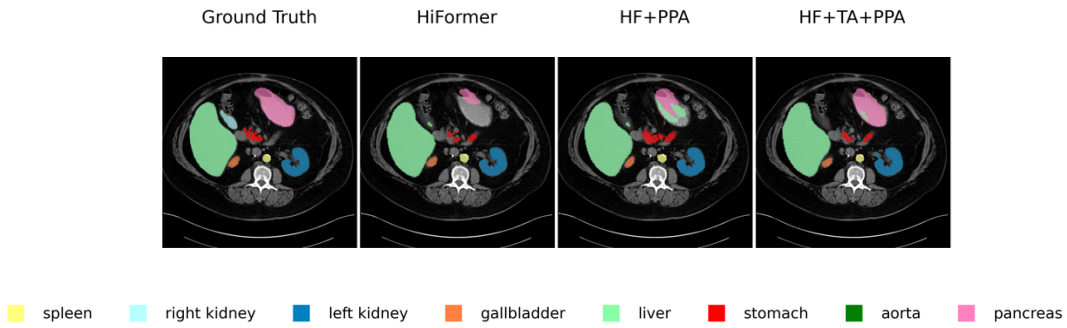

图 5.1 在 Synapse 数据集上使用所提方法的分割结果

5.3 讨论

本研究提出的 HiFormer 模型及其改进版本在 Synapse 多脏器分割任务中展现了卓越的性能，成功融合了 CNN 和 Swin Transformer 的优势，在模型参数效率与分割精度之间取得了良好平衡。实验结果表明，HiFormer 通过双层融合（DLF）模块和注意力机制（PPA、TA）的协同作用，显著提升了对多尺度特征的提取能力，尤其是在小目标器官（如胆囊、胰腺）和复杂解剖结构（如胃部边界）分割方面取得了明显的性能提升。

在模型性能与参数效率方面，HiFormer 仅用 25.51M 参数即可达到 79.73% DSC，优于 TransUnet（105.28M, 77.48% DSC）和 Swin-Unet（27.17M, 79.13% DSC），证明了其 高效的特征提取能力和轻量化设计。其中，DLF 模块通过交叉注意力机制，充分融合 CNN 提取的局部细节特征与 Transformer 提取的全局语义信息，确保了模型在不同尺度下的分割能力。此外，PPA 模块 采用 多分支策略（局部分支、全局分支、卷积分支），显著增强了对小目标器官（如胆囊）和边界细节（如胃部）的识别能力。同时，Triplet Attention（TA）模块通过跨通道和空间交互优化局部特征的敏感性，使 脾脏等高对比度器官的 HD95 降至 14.74，表明模型在边界预测上的稳定性得到提升。

尽管 HiFormer 在多个指标上表现突出，但仍然存在局限性。首先，PPA 模块的多尺度特征融合在提升分割精度的同时，可能会增加边界预测的不稳定性，导致 HD95 值在某些器官上（如 HF+TA+PPA 方案，HD95＝20.25）略有上升。其次，由于 Synapse

数据集样本量较小（仅 30 例），模型的泛化能力在器官形态多变的情况下（如胰腺分割）仍有待提升。此外，PPA 采用的多分支计算策略可能带来一定的计算开销，未来需要优化轻量化架构以提高模型在临床应用中的实时性。

与现有方法相比，HiFormer 在参数量相近的情况下，性能显著优于 Swin-Unet（纯 Transformer 结构）和 DeepLabv3+（传统 CNN 结构）。在肾脏分割任务中，HiFormer 的 DSC（85.52%）较 Swin-Unet（83.28%）提升 2.24%，展现了混合架构的全局-局部特征互补优势。然而，在低对比度器官（如胰腺）的分割任务上，模型仍有优化空间，需要进一步调整特征融合策略以增强复杂解剖结构的辨识能力。

5.4 本章小结

本章围绕 HiFormer 模型及其改进版本在 Synapse 多脏器分割数据集上的实验结果展开分析，全面评估了模型在分割精度、边界预测能力和参数效率等方面的表现。通过与多种基准方法对比，HiFormer 展现出较强的综合优势。在不增加模型复杂度的前提下，融合了 PPA 和 Triplet Attention 模块的 HiFormer 进一步提升了性能，证明了局部细节建模与全局特征捕捉的协同作用。性能评估表明，HiFormer+TA+PPA 在 DSC 和 HD 等关键指标上均优于大多数现有方法，尤其在小器官和复杂边界的分割中具有显著优势。视觉化结果也直观验证了模型的边界精细化能力。同时，参数量对比显示，HiFormer 拥有较小模型规模的同时仍能保持优异表现，具备良好的实用性和部署潜力。尽管如此，本章也指出了模型当前的局限性，包括边界稳定性受多尺度融合影响、样本量限制下的泛化能力不足，以及 PPA 模块在计算效率上的潜在瓶颈。未来研究可在进一步优化轻量化结构、提升对复杂结构识别能力等方面展开，以推动 HiFormer 在临床实际中的应用落地。

6. 结论

本文使用并改进了一种医学图像分割模型——HiFormer，结合了卷积神经网络（CNN）和 Transformer 的优势，针对传统 U-Net 和基于 Transformer 的方法在多脏器分割任务中的不足，提出了创新性的改进。通过引入 PPA（Pyramid Pooling Attention）和 TA（Transformer Attention）模块，HiFormer 在多个医学图像分割任务中展现了显著的性能提升。

实验结果表明，HiFormer 在 Synapse 多脏器分割数据集上，取得了优于大部分现有方法的结果，尤其在脏器边界捕捉和细节分割方面表现突出。相比传统 CNN 基础的模型，HiFormer 通过合理结合 Transformer 和 CNN 的优点，达到了更高的分割精度和较低的计算复杂度。此外，PPA 和 TA 模块的引入有效地提高了模型的多尺度特征提取能力和局部特征学习能力，为模型在处理复杂解剖结构时提供了更强的表现力。

本文得出的研究成果具有重要理论与应用价值。通过高精度自动化分割减少医生手动标注时间，助力快速诊断与治疗决策；为放射治疗剂量计算、手术路径规划提供可靠解剖结构参考，降低手术风险；通过混合架构设计增强模型对多模态数据（CT/MRI/PET）及不同医疗设备成像差异的适应性，推动智慧医疗平台建设；轻量化设计使模型可部署于移动设备或边缘计算节点，服务于基层医疗与远程医疗场景。本研究不仅为医学影像分割提供了新的技术路径，更为推动人工智能辅助诊断系统的实用化与普惠化奠定了理论基础。

尽管 HiFormer 在多脏器分割任务中取得了显著的成果，但仍有一些方面可以进一步优化和扩展。在医学图像处理中，多模态数据（如 CT、MRI、PET 等）能提供更多的信息。未来的研究可以考虑将 HiFormer 扩展到多模态图像分割任务，进一步提高分割的准确性和鲁棒性；本文提出的 HiFormer 模型已经在多个指标上表现出色，但仍可以进一步优化。例如，探索更高效的 Transformer 模块和自注意力机制，减少模型计算量，同时保证分割精度；将 HiFormer 应用于不同数据集或不同类型的医学图像分割任务中，可以考虑结合迁移学习方法，利用预训练模型提高模型在新数据集上的泛化能力；在实际应用中，尤其是临床诊断环境中，实时性和模型效率非常重要。未来的研究可以考虑使用模型压缩和加速技术（如剪枝、量化等）来提升 HiFormer 的计算效率，便于

在资源受限的设备上部署；自监督学习可以在没有大量标注数据的情况下进行有效训练，这对于医学图像领域非常有意义。在数据标注稀缺的情况下，未来的研究可以探索将 HiFormer 与自监督学习方法结合，提升模型的学习能力。

综上所述，HiFormer 模型为医学图像分割提供了一种高效且具有较强实际应用潜力的解决方案，未来的优化和扩展将进一步推动其在医学影像诊断中的应用，并为相关领域提供更多的研究方向。

参考文献

[1] RAMESH K, KUMAR G K, SWAPNA K, et al. A review of medical image segmentation algorithms [J]. EAI Endorsed Transactions on Pervasive Health & Technology, 2021, 7(27).

[2] AZAD R, AGHDAM E K, RAULAND A, et al. Medical image segmentation review: The success of u-net [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024.

[3] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [J]. Advances in neural information processing systems, 2017, 30.

[4] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale [J]. arXiv preprint arXiv:201011929, 2020.

[5] YAO W, BAI J, LIAO W, et al. From cnn to transformer: A review of medical image segmentation models [J]. Journal of Imaging Informatics in Medicine, 2024, 37(4): 1529-47.

[6] RAYED M E, ISLAM S S, NIHA S I, et al. Deep learning for medical image segmentation: State-of-the-art advancements and challenges [J]. Informatics in Medicine Unlocked, 2024: 101504.

[7] SHEN D, WU G, SUK H-I. Deep learning in medical image analysis [J]. Annual review of biomedical engineering, 2017, 19(1): 221-48.

[8] KAYALIBAY B, JENSEN G, VAN DER SMAGT P. CNN-based segmentation of medical imaging data [J]. arXiv preprint arXiv:170103056, 2017.

[9] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation; proceedings of the Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18, F, 2015 [C]. Springer.

[10] CHEN L-C, ZHU Y, PAPANDREOU G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation; proceedings of the Proceedings of the European conference on computer vision (ECCV), F, 2018 [C].

[11] SCHLEMPER J, OKTAY O, SCHAAP M, et al. Attention gated networks: Learning to leverage salient regions in medical images [J]. Medical image analysis, 2019, 53: 197-207.

[12] XIAO H, LI L, LIU Q, et al. Transformers in medical image segmentation: A review [J]. Biomedical Signal Processing and Control, 2023, 84: 104791.

[13]LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows; proceedings of the Proceedings of the IEEE/CVF international conference on computer vision, F, 2021 [C].

[14]PU Q, XI Z, YIN S, et al. Advantages of transformer and its application for medical image segmentation: a survey [J]. BioMedical engineering online, 2024, 23(1): 14.

[15]CHEN J, LU Y, YU Q, et al. Transunet: Transformers make strong encoders for medical image segmentation [J]. arXiv preprint arXiv:210204306, 2021.

[16]HEIDARI M, KAZEROUNI A, SOLTANY M, et al. Hiformer: Hierarchical multi-scale representations using transformers for medical image segmentation; proceedings of the Proceedings of the IEEE/CVF winter conference on applications of computer vision, F, 2023 [C].

[17]WOO S, PARK J, LEE J-Y, et al. Cbam: Convolutional block attention module; proceedings of the Proceedings of the European conference on computer vision (ECCV), F, 2018 [C].

[18]XU S, ZHENG S, XU W, et al. Hcf-net: Hierarchical context fusion network for infrared small object detection; proceedings of the 2024 IEEE International Conference on Multimedia and Expo (ICME), F, 2024 [C]. IEEE.

[19]MISRA D, NALAMADA T, ARASANIPALAI A U, et al. Rotate to attend: Convolutional triplet attention module; proceedings of the Proceedings of the IEEE/CVF winter conference on applications of computer vision, F, 2021 [C].

[20]MICCAI 2015 Multi-Atlas Abdomen Labeling Challenge [Z]. 2015.https://doi.org/10.7303/syn3193805

[21]CAO H, WANG Y, CHEN J, et al. Swin-unet: Unet-like pure transformer for medical image segmentation; proceedings of the European conference on computer vision, F, 2022 [C]. Springer.

[22]ASADI R, QUEGUINEUR A, WIIKINKOSKI O, et al. Process monitoring by deep neural networks in directed energy deposition: CNN-based detection, segmentation, and statistical analysis of melt pools [J]. Robotics and Computer-Integrated Manufacturing, 2024, 87: 102710.

[23] LIANG J, GU X, JIANG D, et al. CNN-based network with multi-scale context feature and attention mechanism for automatic pavement crack segmentation [J]. Automation in Construction, 2024, 164: 105482.

[24] OKTAY O, SCHLEMPER J, FOLGOC L L, et al. Attention u-net: Learning where to look for the pancreas [J]. arXiv preprint arXiv:180403999, 2018.

[25] SALEH T, WENG X, HOLAIL S, et al. DAM-Net: Flood detection from SAR imagery using differential attention metric-based vision transformers [J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2024, 212: 440-53.

[26] NIMMA D, ZHOU Z. IntelPVT: intelligent patch-based pyramid vision transformers for object detection and classification [J]. International Journal of Machine Learning and Cybernetics, 2024, 15(5): 1767-78.

[27] SONG B, KC D R, YANG R Y, et al. Classification of mobile-based oral cancer images using the vision transformer and the Swin transformer [J]. Cancers, 2024, 16(5): 987.

[28] TOUVRON H, CORD M, DOUZE M, et al. Training data-efficient image transformers & distillation through attention; proceedings of the International conference on machine learning, F, 2021 [C]. PMLR.

[29] AZAD R, ARIMOND R, AGHDAM E K, et al. DAE-Former: Dual Attention-Guided Efficient Transformer for Medical Image Segmentation; proceedings of the 6th International Workshop on Predictive Intelligence in Medicine (PRIME), Vancouver, CANADA, F Oct 08, 2023 [C]. 2023.

[30] LIANG Z W, ZHAO K, LIANG G, et al. MAXFormer: Enhanced transformer for medical image segmentation with multi-attention and multi-scale features fusion [J]. Knowledge-Based Systems, 2023, 280.

[31] LIU X, GAO P, YU T, et al. CSWin-UNet: Transformer UNet with cross-shaped windows for medical image segmentation [J]. Information Fusion, 2025, 113.

[32] KIRILLOV A, GIRSHICK R, HE K, et al. Panoptic feature pyramid networks; proceedings of the Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, F, 2019 [C].

[33]FU S, LU Y, WANG Y, et al. Domain adaptive relational reasoning for 3d multi-organ segmentation; proceedings of the Medical Image Computing and Computer Assisted Intervention–MICCAI 2020: 23rd International Conference, Lima, Peru, October 4–8, 2020, Proceedings, Part I 23, F, 2020 [C]. Springer.

[34]XU G, ZHANG X, HE X, et al. Levit-unet: Make faster encoders with transformer for medical image segmentation; proceedings of the Chinese Conference on Pattern Recognition and Computer Vision (PRCV), F, 2023 [C]. Springer.

致 谢

首先，我要衷心感谢我的指导教师杨涛教授。在整个论文的研究过程中，杨老师给予了我无私的指导和耐心的支持。每当我遇到困惑和困难时，杨老师总是耐心地帮助我分析问题、提出解决方案，并不断激励我克服挑战。杨老师不仅在学术上给予我重要指导，更在思想和人生道路上为我树立了榜样，我深感荣幸能在您的指导下完成这项研究工作。

我还要感谢曾经支持和协助我完成论文课题研究工作的梁立新老师。梁老师为我提供了宝贵的研究资源和专业建议，在论文的各个阶段给予了我及时的反馈和帮助，使我的研究工作能够顺利推进。

感谢未来技术学院的所有技术人员和老师们，感谢你们提供的技术支持与设施保障。在实验和数据处理过程中，您们的帮助是我顺利完成研究的重要保障。

同时，我也要特别感谢我的研究生师兄们和合作伙伴们。在团队合作中，师兄们为我提供了许多专业的指导和建议，分享了宝贵的经验，大家的共同努力和支持是我完成研究不可或缺的一部分。

最后，我要特别感谢我的父母和家人。感谢你们在我求学过程中给予的无私支持和理解，正是有了你们的支持，我才能在学术的道路上坚持不懈、勇往直前。你们的爱和鼓励是我不断前行的动力源泉。

再次感谢所有帮助、支持和鼓励我的人，是你们的关爱和帮助成就了我的学术成长与论文的完成。